

本项目是一个基于 RAG (Retrieval-Augmented Generation, 检索增强生成) 的 PDF 知识库问答系统。用户可以上传 PDF 文件, 系统会自动解析、切分、向量化并存入向量数据库。之后用户可以用自然语言提问, 系统会从 PDF 中检索相关内容, 并调用大语言模型生成准确答案, 同时显示答案来源。

项目采用前后端分离架构, 后端提供 REST API, 前端提供可视化操作界面。

技术栈

编程语言: Python 3.11

后端框架: FastAPI

RAG 框架: LangChain

向量数据库: ChromaDB

嵌入模型: BAAI/bge-small-zh-v1.5 (中文嵌入模型)

大语言模型: DeepSeek API (兼容 OpenAI 接口)

关系型数据库: MySQL (存储对话历史)

前端框架: Streamlit

部署工具: Uvicorn

功能列表

1. PDF 上传与索引: 支持上传 PDF 文件, 自动完成文本提取、切分、向量化并存入 ChromaDB。
2. 智能问答: 基于上传的 PDF 内容进行多轮问答, 答案严格来源于文档。
3. 来源引用: 每条回答都会显示引用的 PDF 文件名, 方便溯源。
4. 对话历史: 所有问答记录自动保存到 MySQL, 支持按会话 ID 查询历史。
5. 文档删除: 支持按文件名删除已上传的 PDF 及其对应的向量数据。
6. 可视化界面: 基于 Streamlit 的前端界面, 支持上传、聊天、加载历史等操作。

项目结构

rag-demo/

- ├── .env # 环境变量配置（API 密钥、数据库密码）
- ├── requirements.txt # 项目依赖清单
- ├── init_db.sql # MySQL 建表语句
- ├── db.py # MySQL 连接与操作
- ├── rag_core.py # RAG 核心逻辑（加载、切分、向量化、检索、生成）
- ├── main.py # FastAPI 后端接口
- ├── app.py # Streamlit 前端界面
- ├── data/ # 存放上传的 PDF 文件
- └── chroma_db/ # ChromaDB 向量数据库持久化目录

安装与运行

1. 环境准备

安装 Python 3.11

安装 MySQL（可使用 Docker）

安装 Git

2. 创建虚拟环境

```
conda create -n rag-demo python=3.11 -y
```

```
conda activate rag-demo
```

3. 安装依赖

```
pip install -r requirements.txt
```

4. 配置环境变量

在项目根目录创建 `.env` 文件，内容如下：

OPENAI_API_KEY=你的 DeepSeek 密钥
OPENAI_BASE_URL=<https://api.deepseek.com>
LLM_MODEL=deepseek-v4-flash

DB_HOST=localhost
DB_PORT=3306
DB_USER=root
DB_PASSWORD=你的 MySQL 密码
DB_NAME=rag_demo

5. 初始化数据库

在 MySQL 中执行 `init_db.sql` 文件，创建数据库和表。

6. 启动后端

```
uvicorn main:app --reload --port 8000
```

7. 启动前端

另开一个终端，执行：

```
streamlit run app.py
```

浏览器会自动打开 <http://localhost:8501>

常见问题

Q: 模型下载很慢怎么办？

A: 可以设置 Hugging Face 国内镜像。Windows 用户执行 `set HF_ENDPOINT=https://hf-mirror.com`，Mac/Linux 用户执行 `export HF_ENDPOINT=https://hf-mirror.com`。

Q: 报错 `ModuleNotFoundError: No module named 'dotenv'`？

A: 说明当前环境不对，请确认已激活 `rag-demo` 环境，并重新安装依赖。

Q: ChromaDB 报错 Embedding dimension does not match?

A: 嵌入模型改变后需要删除 chroma_db 文件夹，重新上传 PDF 重建向量库。

Q: MySQL 连接失败?

A: 检查 .env 中的数据库配置，确保 MySQL 服务已启动，且 rag_demo 数据库已创建。

Q: DeepSeek API 报错 401?

A: 检查 API Key 是否正确，账户是否有余额。

许可证

本项目仅用于学习与演示，代码开源，可自由使用。